비정형데이터분석
-Final Presentation-

SEOULTECH

대학수학능력시험 및 수능 모의평가 영어 영역 기출문제 학습을 통한 출제문항(어휘, 구문, 지문) 분석 및 예측

2021.12.06

* 데이터사이언스학과 석사과정 권도윤 (21510093)
* 데이터사이언스학과 석사과정 김재호 (21512070)
* 데이터사이언스학과 박사과정 김진홍 (21522016)

주제선정 배경 (주제명 : 대학수학능력시험 및 수능 모의평가 영어 영역 기출문제 학습을 통한출제문항(어휘, 구문, 지문) 분석 및 예측)

✓ 월 평균 사교육비는 여전히 지속적인 증가 추세를 나타내며, 그 중 영어 교과의 사교육비 지출비율이 가장 높은 경향을 보이고 있음

✓ 수능영어의 절대평가 전환에 따라 변별력 구분을 위한 기형적인 고난도 문항이 없어지고, 논란이 적으며 핵심적이고 중요한 내용 중심으로 출제

사회 > 사회일반

수능영어 절대평가 4년…난이도 널뛰고 사교육비 치솟았다

입력 2021-03-11 06:30:16 수정 2021.03.11 06:30:16 김창영 기자

도입 이후 등급별 비중 들쑥날쑥
당초 취지와 달리 학원 의존 심화
월평균 사교육비 21.7만원 '최대'
영어 대신 他영역 반영 비율 높여
특정과목에 당락 갈리는 부작용도

최근 4년간 수능 영어 등급별 비중 추이 (단위:%)

등급	2018	2019	2020	2021
1	10.0	5.3	7.4	12.7
2	19.6	14.3	16.2	16.5
3	25.4	18.5	21.9	19.7
4	18.0	20.9	18.5	18.6
5	10.5	16.5	12.3	13.5
6	6.7	10.7	9.2	9.0
7	4.7	7.4	7.4	5.6
8	3.5	4.6	5.2	3.4
9	1.5	1.7	1.9	1.0

자료: 한국교육과정평가원

HOME > 교육일반 > 초·중·고 교육

월 평균 사교육비 30만원 돌파…여전한 '사교육 공화국'

백두산 기자 | 승인 2021.01.27 16:41 | 댓글 0

한경연, '우리나라 교육지표 현황과 사교육 영향 분석' 보고서 발표
공교육 확대에도 사교육 참여율 여전히 높아…2019년 초중고 1인당 월 사교육비 32만 1천원
주당 사교육 참여시간 3.6시간으로 조사 대상 OECD 국가 중 1위…OECD 평균 6배
사교육 받는 학생이 상위권 속할 확률 수학 56.3%↑, 영어 53.2%↑

공교육 재정이 꾸준히 확대됐지만 사교육의 영향이 여전히 크다는 연구보고서가 발표됐다. 사교육을 받는 학생이 학교성적에서 상위권에 속할 확률이 높다는 분석이다. 초중고 학생들의 1인당 월평균 사교육비는 2007년 조사 이후 처음으로 30만원을 넘어섰다. 사진=대학저널 DB

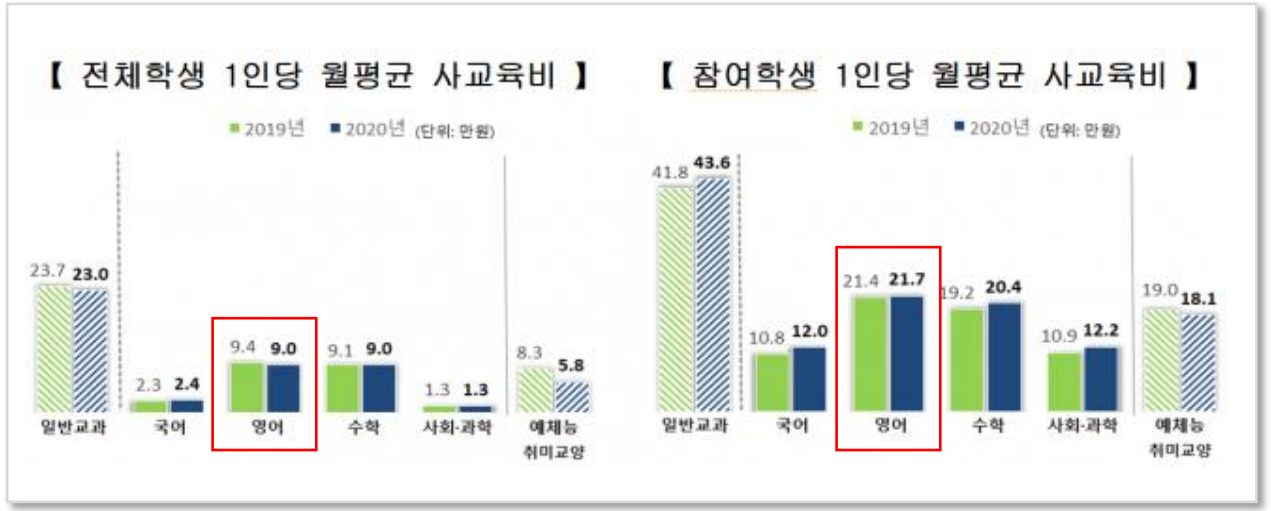

연도	추 진 내 용			'18학년도 수험생
'14년	2018학년도 수능영어 절대평가 도입 방안 발표(~'14.12월)			중3
'15년	점수체제 및 시험체제 등 세부 도입방안 마련(상반기)	⇒	2018학년도 대입전형 기본사항 발표시 반영(8월)	고1
'16년	2018학년도 대학별 대입전형시행계획 발표(4월)	⇒	절대평가 체제의 난이도 안정화 방안 마련·검증(하반기)	고2
'17년	절대평가체제의 모의평가 진행 (6월/9월)	⇒	본 수능 시행 (11월)	고3

수능 영어 절대평가 전환에 대한 찬반 쟁점

찬성	쟁점	반대
쉬운 영어 중심 전환 영어 사교육 심화 해소	사교육	수학·국어 등 사교육 풍선효과, 현재 영어 사교육은 초·중학교 중심
상대평가 과열 경쟁과 등급화 위한 기형적인 고난도 문항 없어져	학습 부담	쉬운 영어 강화돼 대학들이 별도의 영어전형 도입하면 학생 부담은 옥상옥이 될 가능성
국가공인 절대평가 체제와 수능 체제 개편해서 영어를 통과(패스) 과목으로 전환 가능	평가 방식	절대평가 방식인 국가영어능력시험 (NEAT)으로 수능 대체 검토했던 계획은 무산, 수능에서 영어 선택과목 유지 시 타 과목과의 형평성 문제 생겨

Project Overview

➢ 프로젝트명 : 대학수학능력시험 및 수능 모의평가 영어 영역 기출문제 학습을 통한 출제문항 (어휘, 구문, 지문) 분석 및 예측

➢ 인 원 : 김진홍 (21-2 박사 입학), 권도윤 (21-1 석사 입학), 김재호 (21-2 석사 입학)

➢ 기간 : 21.10.18 ~ 21.12.06

➢ 데이터셋 : 2016 ~ 2021년 6월,9월 평가원 기출 12회분, 2016~2021 수능 기출 5회분 (총 17회분)

➢ 분석환경 구축

- Google Drive
- Excel
- Python 3.7 ~
  - ✓ Pandas, numpy
  - ✓ Matplotlib, seaborn,
  - ✓ sklearn 등

➢ 커뮤니케이션 :

- 오프라인 : 주 1회 이상, 프론티어관 EDM-Lab 307-1호
- 온라인 : KakaoTalk (메신져), Zoom (회의용)

➢ Project R&R

이름	소속	Role & Responsibilities
김진홍	서비스혁신연구실 (금영정 교수님 지도)	- 프로젝트 진행관련 Background 조사 및 분석 ★ - 프로젝트 Advanced Part 분석 진행 ★★★ - 데이터 수집 및 전처리 진행 (공통)
권도윤	응용확률 Lab 심민규 교수님 지도	- 데이터 수집을 위한 전처리 기준 수립 및 가이드제작 ★ - 프로젝트 Basic Part 분석 진행 ★★★ - 데이터 수집 및 전처리 진행 (공통)
김재호	EDM Lab (홍정식 교수님 지도)	- 프로젝트 기획 및 보고서 작성 ★★★ - 프로젝트 진행관리 및 분석결과 검증 ★ - 데이터 수집 및 전처리 진행 (공통)

➢ Project Schedule

Phase	주요내용	10월		11월					12월
		7주차 (10.18)	8주차 (10.25)	9주차 (11.02)	10주차 (11.08)	11주차 (11.15)	12주차 (11.22)	13주차 (11.29)	14주차 (12.06)
주제 선정	주제선정	● ⇢	⇢						
	목표설정	● ⇢	⇢						
	제안서 발표		✓						
데이터 수집/분석	데이터 수집		● ⇢	⇢					
	데이터 전처리			● ⇢	⇢	⇢			
	데이터 분석/검증					● ⇢	⇢	⇢	
검증 및 결과보고	최종보고 준비							● ⇢	⇢
	최종 발표								✓

데이터 수집

✓ EBS-i 홈페이지를 통해 2016년 부터 2021년 까지 총 17회 분량의 평가원 및 수능 기출 문제와 해설자료를 다운 받았음

✓ 수집한 데이터는 PDF 파일 형태로 분석을 위한 별도의 전처리가 필요하였고, 우선 수집한 데이터는 구글 드라이브 프로젝트 폴더에 보관하여 공유 및 협업 할 수 있도록 준비하였음

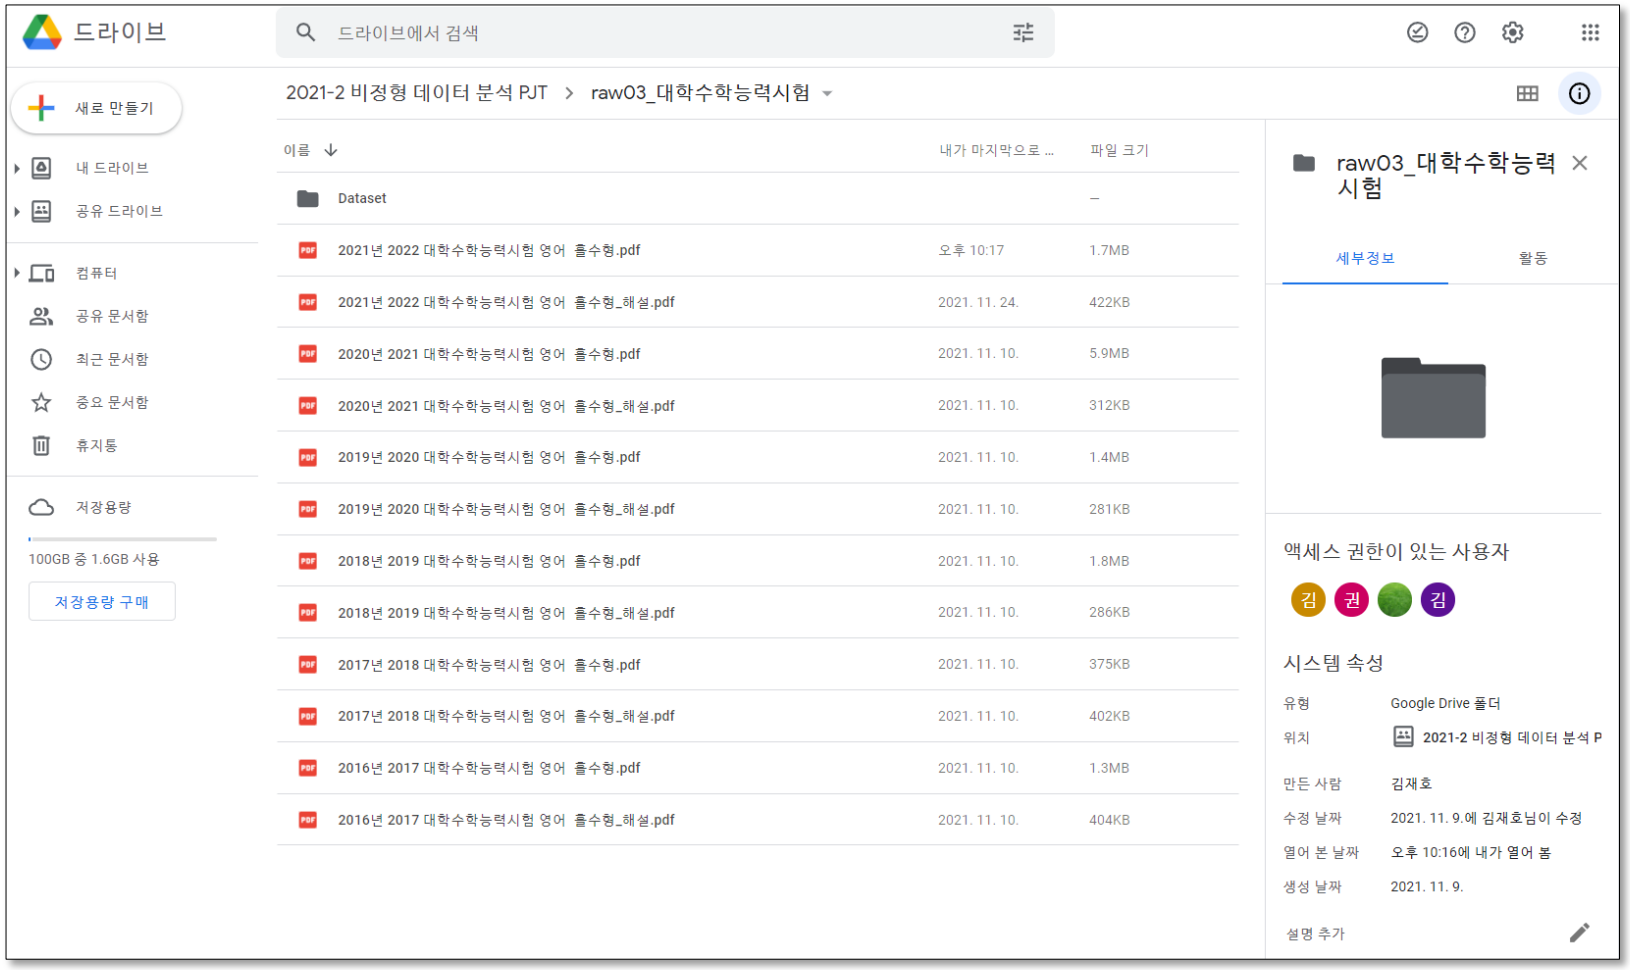

데이터 전처리

✓ PDF를 크롤링 하여 문항별로 지문추출 하는 방법을 검토하였으나, 보기, 빈칸 처리 등 변수 사항들이 많은 관계로 조원들과 배분하여 데이터 수집을 수작업으로 진행하였음

✓ 데이터 수집을 위한 기준을 마련하였으며, 읽기영역 28문제 / 25개 지문에서 그림 문제 지문 2개를 제외하고 23개 지문에 대해서만 데이터 수집 및 전처리 작업을 진행함

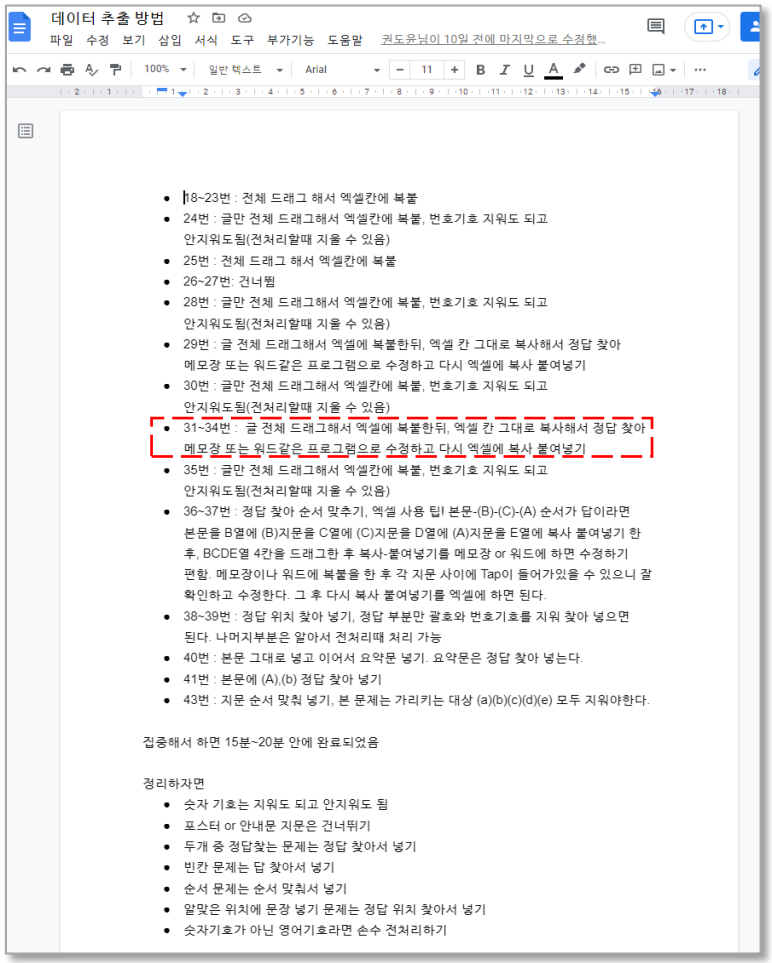

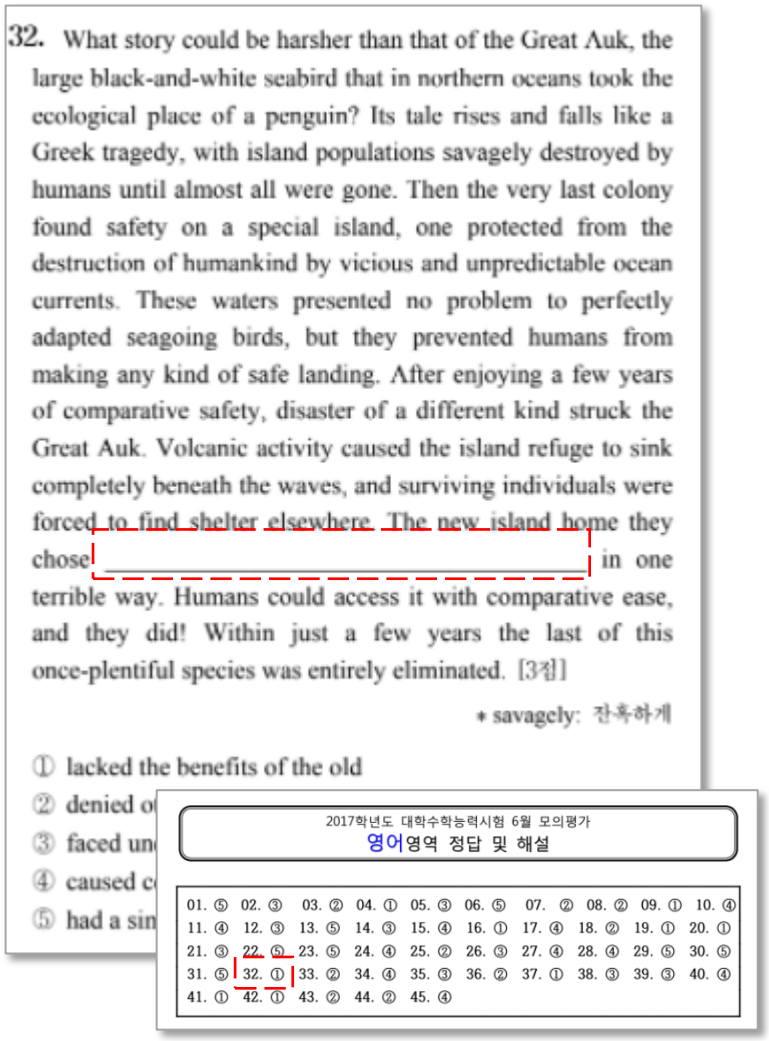

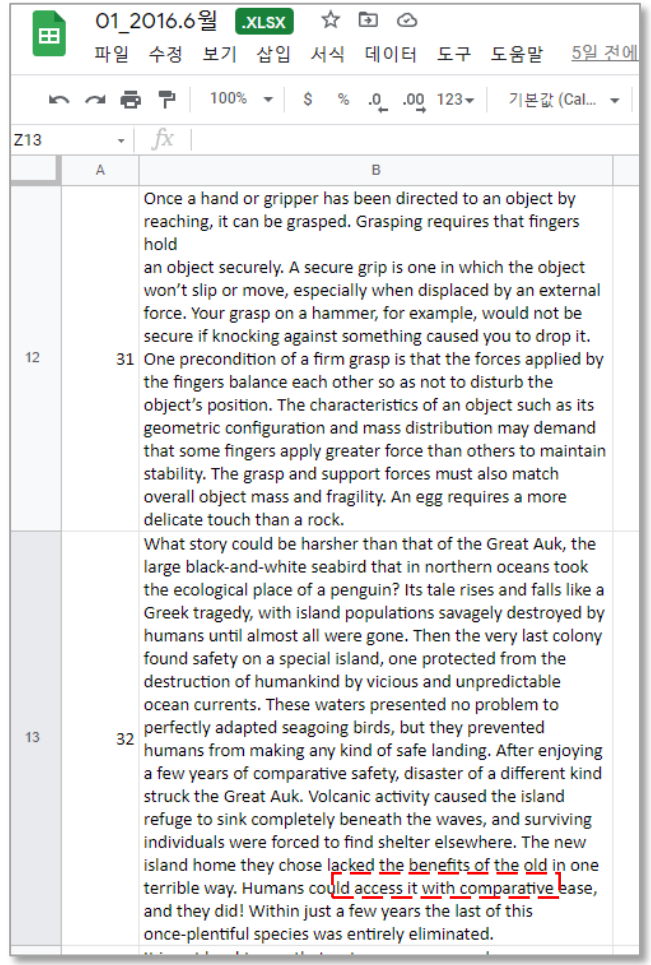

데이터 분석 모델 및 목표

✓ 제안발표 당시 수능 출제 문항은 기출문제들의 seq to seq 모델링을 따를 것이라는 개념으로 생각하고 학습을 통한 토큰 예측을 진행하고자 하였으나, 학습지식 부족 및 프로젝트 진행 스케줄 등의 이유로 각 기출문제 데이터 전체를 일괄적으로 병합하여 분석을 진행하였음

■ As-is (Proposal Presentation, seq to seq modeling concept)

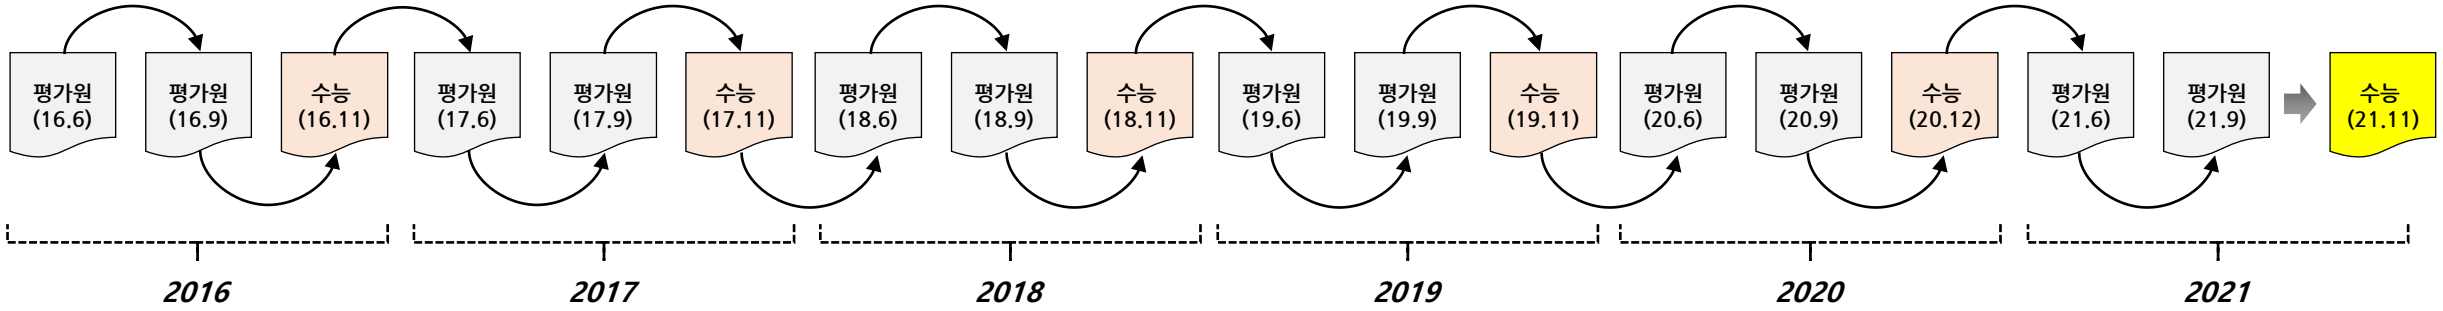

■ To-Be

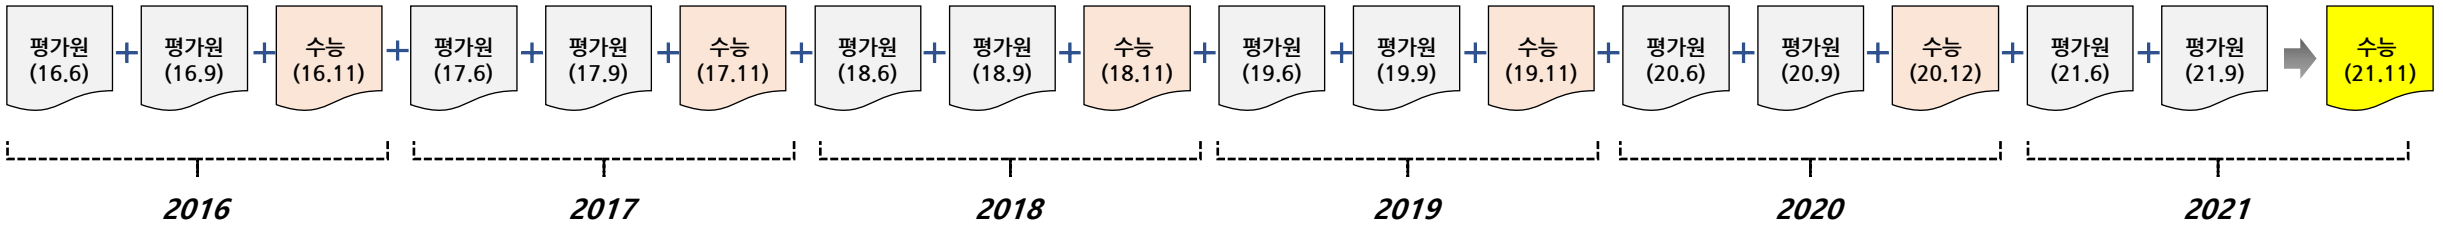

Basic part

- 2021년 수능 기출문제 지문분석 (토큰수, 사용빈도수 문장수 등)
- 2016~2021 모의평가 및 수능 기출 분석 (토큰수, 누적토큰수, 일치율 등)

Advanced Part

- 품사 태깅 및 표제어 추출(Lemmatization)을 통한 토큰 일치율 비교
- 코사인 유사도 비교를 통한 지문/장르 일치율(%) 비교

Basic Part Ⅰ (2021년 수능 기출문제 분석)

✓ 2021년 수능 영어 기출(21,11,18일 시행) 문제의 읽기영역 지문 23개를 분석한 결과 23,519개 문자로 총 문장수는 183개, 불용어 제외시 2,236개 토큰이 사용되었음

✓ 수능 지문은 평균적으로 1,030여개 문자로 8개의 문장, 불용어 제외시 97개의 토큰으로 구성되었음

①

	A	B	C	D
1	number	contents		
2	18	Dear Ms. Green, My name is Donna Williams, a science teacher at Rogan Hi		
3	19	It was Evelyn's first time to explore the Badlands of Alberta, famous across C		
4	20	One of the most common mistakes made by organizations when they first co		
5	21	Scientists have no special purchase on moral or ethical decisions; a climate s		
6	22	Environmental hazards include biological, physical, and chemical ones, along		
7	23	Scientists use paradigms rather than believing them. The use of a paradigm in		
8	24	Mending and restoring		
9	25	The above graphs show		
10	28	Donato Bramante, born		
11	29	Like whole individuals,		
12	30	It has been suggested		
13	31	Humour involves not jus		
14	32	News, especially in its		
15	33	Elinor Ostrom found tha		
16	34	Precision and determin		
17	35	Since their introduction		
18	36	According to the marke		
19	37	In spite of the likeness		
20	38	Introduction of robots in		
21	39	Cinema is valuable not		
22	40	Philip Kitcher and Wes		
23	41	Classifying things toge		
24	43	In the gym, members c		
25				

②

<코드1>

```
num_len=0
sent_num=0
max_sent=0
min_sent=0
nostop_token=0
stop_token=0
stop_words = set(stopwords.words('english'))
da=np.array([])
for i in range(len(df)):
    num_len=(len(df["contents"][i]))
    sent_tokens = sent_tokenize(df["contents"][i])
    sent_num=(len(sent_tokens))
    max_sent=(len(max(sent_tokens, key=len)))
    min_sent=(len(min(sent_tokens, key=len)))
    mean_sent=0
    for k in (sent_tokens):
        mean_sent+=len(k)
    mean_sent=mean_sent/len(sent_tokens)

    df["contents"][i]=re.sub("[^a-zA-Z0-9]"," ",df["contents"][i])

    nostop_token=(len(word_tokenize(df["contents"][i])))

    result = []
    for w in word_tokenize(df["contents"][i]):
        if w not in stop_words:
            result.append(w)
    stop_token=(len(result))
    da=np.append(da,np.array([[df["number"].values[i],num_len,sent_num,max_sent,min_sent,mea
```

▶ 2021년 수능영어 지문 분석

문항 번호	지문길이 (len)	문장수	문장길이(len)			토큰수	
			Max	Min	Mean	(불용어포함)	(불용어제외)
18	637	8	139	25	79	110	69
19	697	9	123	22	77	122	73
20	968	6	249	38	161	165	90
21	1,021	8	269	31	127	171	99
22	1,002	6	239	83	166	149	93
23	1,005	7	224	52	143	157	85
24	994	8	178	40	123	161	95
25	823	6	196	110	136	158	87
28	753	10	123	44	74	131	80
29	1,028	9	153	47	113	170	105
30	1,083	6	272	105	180	168	105
31	825	6	235	72	137	142	74
32	1,084	6	285	114	180	171	102
33	1,022	6	240	139	170	166	91
34	1,165	5	306	194	232	181	94
35	874	6	217	103	145	133	84
36	1,035	7	267	42	147	163	94
37	1,023	7	210	75	145	168	89
38	980	6	321	84	163	155	89
39	1,071	7	210	92	152	174	97
40	1,244	9	182	49	137	180	100
41	1,427	11	283	81	129	257	137
43	1,918	24	187	14	79	349	204
합계	23,519	183	321 (max)	14 (min)	-	3,901	2,236
평균	1,030	8	-	-	139	170	97

※ 그림영역 2개 문항의 지문은 제외하고 계산 하였음

Basic Part Ⅰ (2021년 수능 기출문제 분석)

✓ 2021년 수능 영어 기출문제에 출제된 토큰과 빈도수를 분석하여 시각화를 진행함

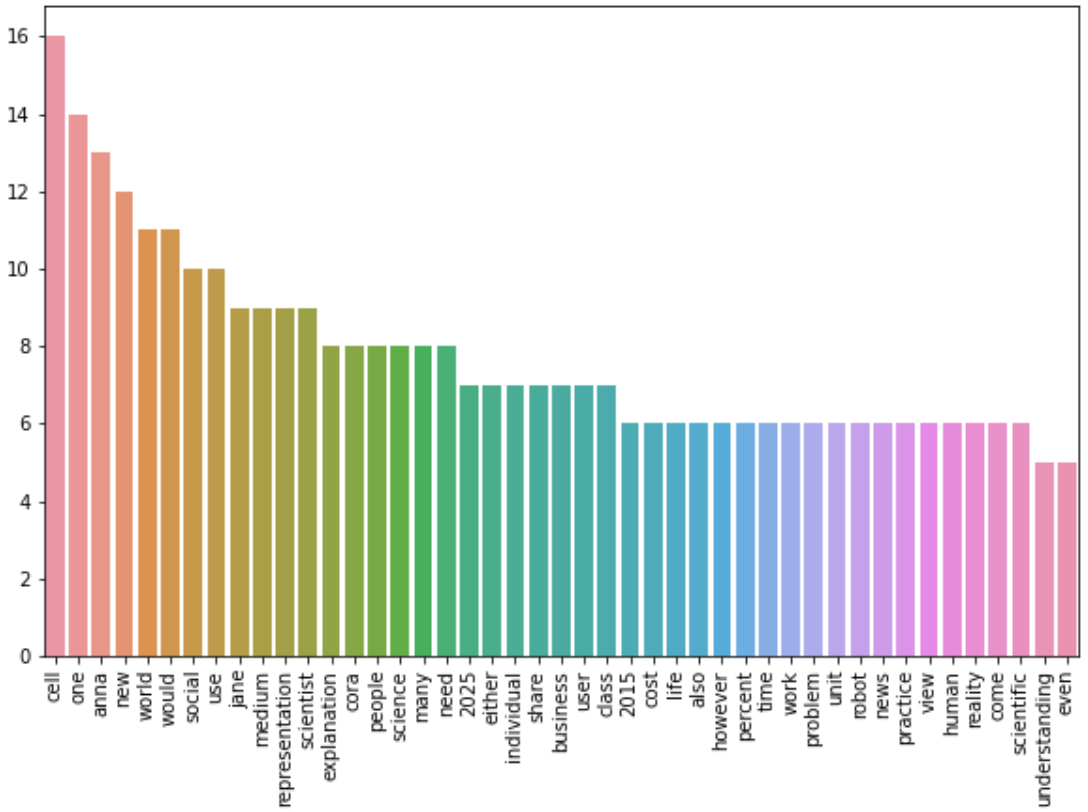

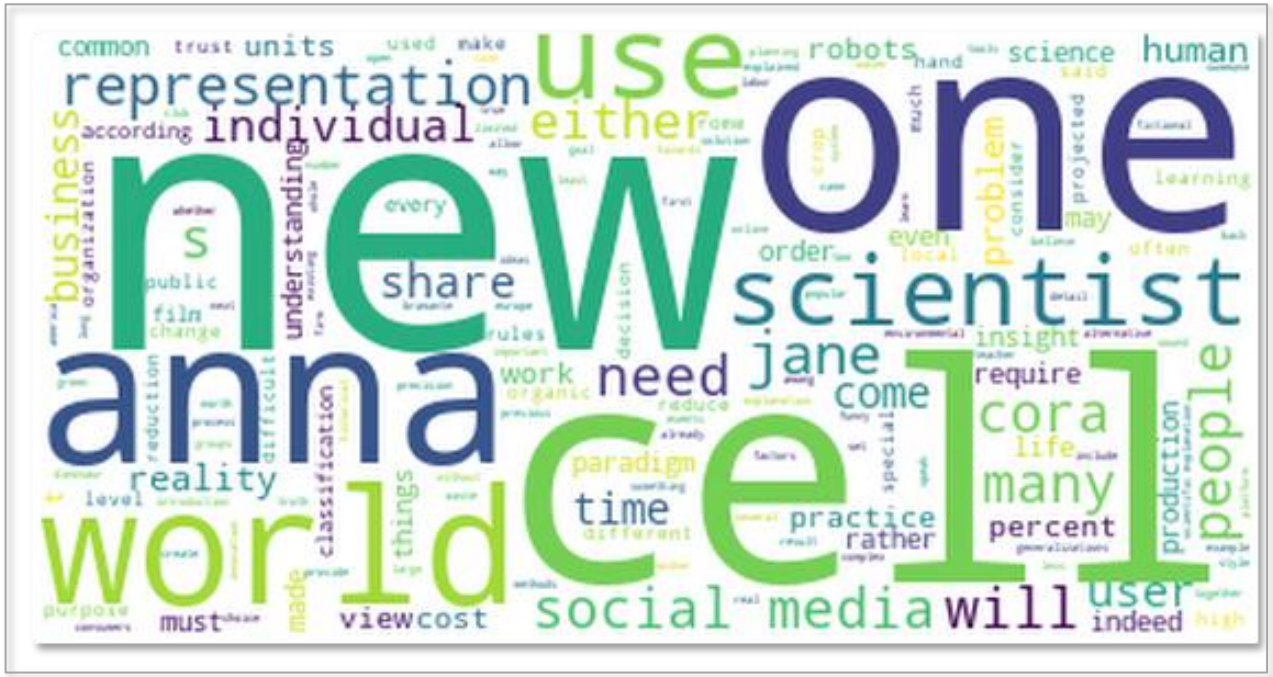

▶ 2021년 수능영어 시험 토큰 리스트 (불용어 제거)

순	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	…	1208	1209	1210
단어	cell	one	anna	new	world	would	social	use	jane	medium	representation	scientist	explanation	cora	people	science	many	need	…	regional	latest	went
빈도수	16	14	13	12	11	11	10	10	9	9	9	9	8	8	8	8	8	8	…	1	1	1

Basic Part Ⅱ (2016년 모의평가 및 수능기출 ~ 2021.9년 모의평가 분석)

✓ 각 년도별 모의평가 기출 단어와 수능시험 기출 단어를 분석하였으며 불용어 제외시 평균 2,162개 토큰으로 지문이 구성되어 있음을 확인함

✓ 각 회차가 누적 될 수록 신규 토큰수 들이 점차 감소되고 있음을 확인할 수 있었음

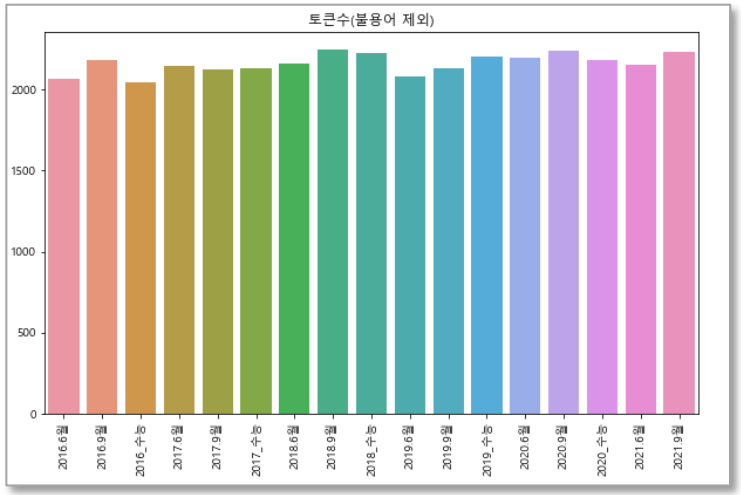

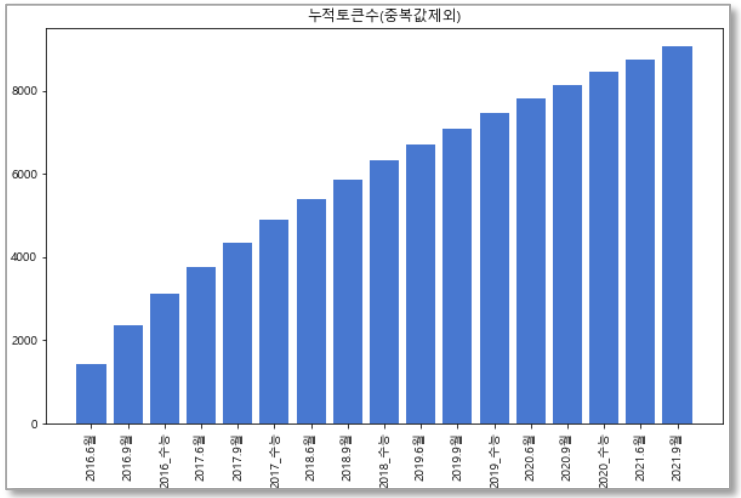

▼ 2016~2021.9 모의평가 및 수능기출 출제 토큰 워드클라우드

구분		2016.6월	2016.9월	2016.수능	2017.6월	2017.9월	2017.수능	2018.6월	2018.9월	2018.수능	2019.6월	2019.9월	2019.수능	2020.6월	2020.9월	2020.수능	2021.6월	2021.9월
토큰수		3,651	3,916	3,544	3,727	3,809	3,749	3,745	3,907	3,798	3,688	3,868	3,824	3,773	3,987	3,914	3,800	3,804
누적 토큰수		3,651	7,567	11,111	14,838	18,647	22,396	26,141	30,048	33,846	37,534	41,402	45,226	48,999	52,986	56,900	60,700	64,504
누적 토큰수 (중복값 제거)		1,415	2,354	3,123	3,769	4,338	4,890	5,399	5,865	6,318	6,711	7,096	7,479	7,828	8,149	8,459	8,763	9,062
불용어 제외	토큰수	2,068	2,183	2,044	2,143	2,126	2,135	2,162	2,245	2,229	2,079	2,130	2,201	2,198	2,237	2,180	2,155	2,234
	누적토큰수	2,068	4,251	6,295	8,438	10,564	12,699	14,861	17,106	19,335	21,414	23,544	25,745	27,943	30,180	32,360	34,515	36,749
	누적 토큰수 (중복값 제거)	1,302	2,227	2,992	3,636	4,204	4,753	5,262	5,728	6,180	6,573	6,958	7,340	7,689	8,009	8,319	8,623	8,921
	신규 토큰수	-	▲ 925	▲ 765	▲ 644	▲ 568	▲ 549	▲ 509	▲ 466	▲ 452	▲ 393	▲ 385	▲ 382	▲ 349	▲ 320	▲ 310	▲ 304	▲ 298

Basic Part Ⅲ (2021년 수능 영어시험 대비 기출문제 일치율 분석)

✓ 각 회차별 출제된 토큰과 2021년 수능 출제 토큰과 일치여부를 비교시 평균 856개의 토큰이 일치하고, 1,380개의 토큰이 불일치 하였으며 평균 38.3%의 일치율을 보여주었음

✓ 각 회차별 토큰이 누적될 수록 토큰수 일치율이 지속적으로 증가하는 경향을 보여주었으며 최종 누적 일치율은 84.5%까지 증가하는 것을 확인함

(2021수능 토큰 : 2,237개)

2021 수능대비 일치여부			2016.6월	2016.9월	2016.수능	2017.6월	2017.9월	2017.수능	2018.6월	2018.9월	2018.수능	2019.6월	2019.9월	2019.수능	2020.6월	2020.9월	2020.수능	2021.6월	2021.9월
일치 토큰수			771	839	845	858	882	799	860	877	887	810	858	913	862	883	891	806	921
불일치 토큰수			1,466	1,398	1,392	1,379	1,355	1,438	1,377	1,360	1,350	1,427	1,379	1,324	1,375	1,354	1,346	1,431	1,316
토큰수 일치율			34.5%	37.5%	37.8%	38.4%	39.4%	35.7%	38.4%	39.2%	39.7%	36.2%	38.4%	40.8%	38.5%	39.5%	39.8%	36.0%	41.2%
회차별누적	중복값제외	일치 토큰수	771	1,081	1,251	1,405	1,517	1,583	1,643	1,691	1,722	1,746	1,769	1,789	1,810	1,828	1,849	1,874	1,891
		불일치 토큰수	1,466	1,156	986	832	720	654	594	546	515	491	468	448	427	409	388	363	346
		토큰수 일치율	34.5%	48.3%	55.9%	62.8%	67.8%	70.8%	73.4%	75.6%	77.0%	78.1%	79.1%	80.0%	80.9%	81.7%	82.7%	83.8%	84.5%

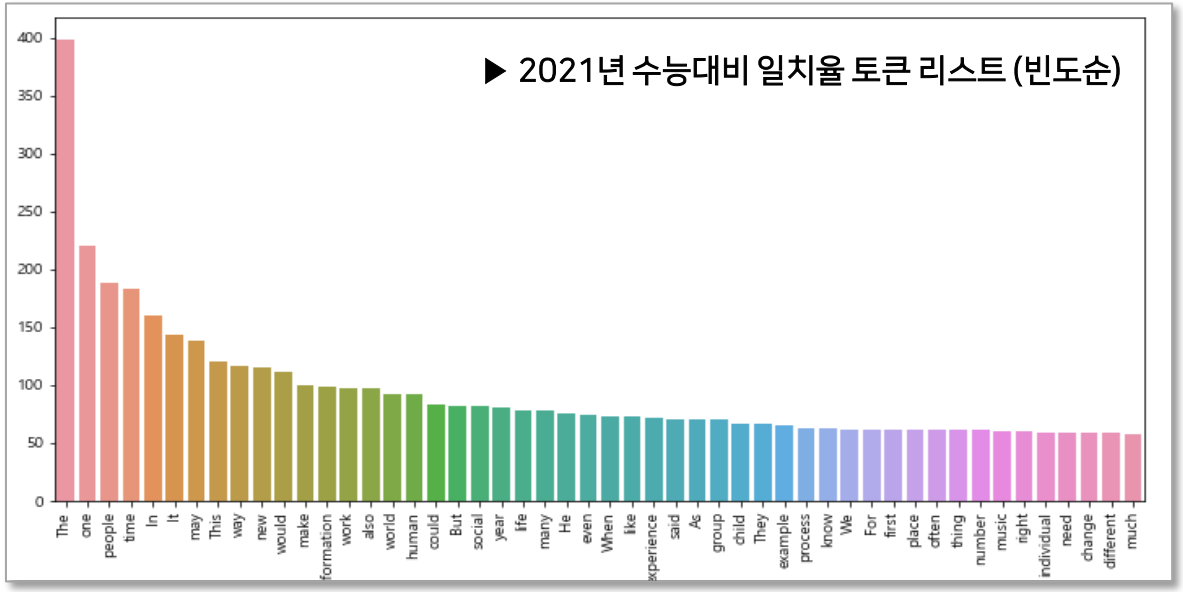

<코드2>

```
result = np.array([])
all_corpus=[]
word_token=0
stacked_token = 0
all_stacked_token = []
all_stacked_len = 0
stacked_stop_token = 0
word_token_len = []
all_stop_stacked_token = []
stop_words = set(stopwords.words('english'))

for file in file_list :
    if file[0][-6:-4] == "6월":
        df = pd.read_csv(file,header=None)
    else :
        df = pd.read_csv(file)

    df=df.dropna()
    df.columns = ["number","contents"]
    df_word = df


    for i in range(len(df)):
        df_word["contents"][i]=re.sub("[0-9]\s","",df_word["contents"][i])
        df_word["contents"][i]=re.sub("[^a-zA-Z0-9]"," ",df_word["contents"][i])

df_2021 = pd.read_csv("18_2021_수능.csv")
for i in range(len(df_2021)):
    df_2021["contents"][i]=re.sub("[0-9]\s","",df_2021["contents"][i])
    df_2021["contents"][i]=re.sub("[^a-zA-Z0-9]"," ",df_2021["contents"][i])
#-----------------------------------------------------------------------


sent_corpus = [sent_tokenize(s) for s in df_word["contents"]]
corpus=[]
for i in sent_corpus:
    corpus=sent_corpus+i

sent_corpus_21 = [sent_tokenize(s) for s in df_2021["contents"]]
corpus_21=[]
for i in sent_corpus_21:
    corpus_21=sent_corpus_21+i
```

```
    #토큰수 불용어 제외
stop_result_21 = []
for i in range(len(corpus_21)):
    for w in word_tokenize(corpus_21[i][0]):
        if w not in stop_words:
            stop_result_21.append(w)

stop_result = []
for i in range(len(corpus)):
    for w in word_tokenize(corpus[i][0]):
        if w not in stop_words:
            stop_result.append(w)

same_num=0
for i in stop_result_21:
    if i in stop_result:
        same_num=same_num+1


for i in sent_corpus:
    all_corpus=all_corpus+i

#누적 토큰수 불용어 제외


#누적토큰수 중복값, 불용어 제외
stop_result = []
for i in range(len(all_corpus)):
    for w in word_tokenize(all_corpus[i]):
        if w not in stop_words:
            stop_result.append(w)

tt=pd.Series(np.array(stop_result)).unique()

all_same_num=0
for i in stop_result_21:
    if i in tt:
        all_same_num=all_same_num+1

result=np.append(result, np.array([[same_num,len(stop_result_21)-same_num,same_num/len
```

Advanced Part Ⅰ (단어 일치율 비교)

✓ 각 년도별 모의평가 기출 단어와 수능시험 기출 단어의 품사 태깅 및 표제어 추출(Lemmatization) 처리를 진행 후 일치율의 비교 분석을 진행함

✓ 6개년도 데이터에 대해 비정형 분석을 수행한 결과, 평균적으로 수능단어의 47.7%가 6월 혹은 9월 모의고사 빈출단어와 일치하는 것으로 산출됨

✓ 일치하는 단어의 난이도는 평이한 수준이며, 고등학생이라면 반드시 알아야만 하는 단어로 구성됨

▶ 단어비교 모델

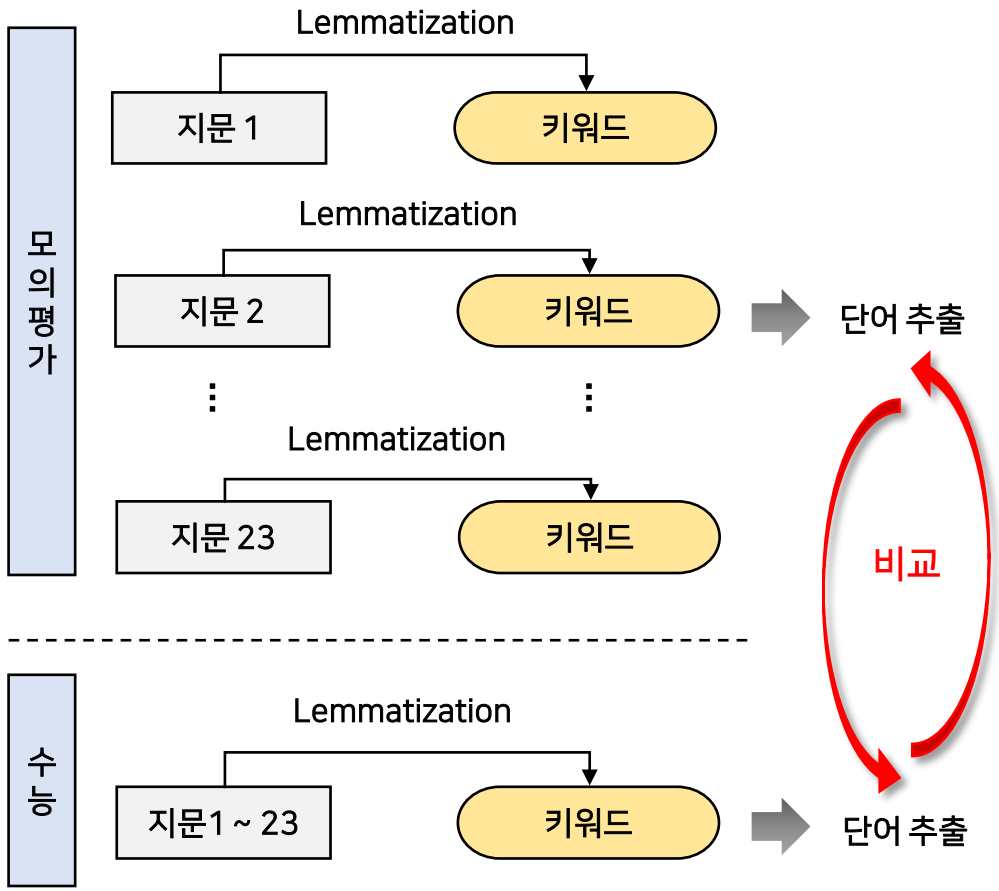

<코드3>

```
def tagwn(tag):

    return {
        'N': wn.NOUN,
        'V': wn.VERB,
        'R': wn.ADV,
        'J': wn.ADJ
    }.get(tag[0],wn.ADJ)


def normalize(text):
    for token, tag in nltk.pos_tag(nltk.wordpunct_tokenize(text)):
        token = token.lower()
        if token in stopwords or token in punctuation:
            continue
        token = lemmatizer.lemmatize(token, tagwn(tag))
        yield token
```

⇒ *Pos tagging*

⇒ *Lemmatization*

▶ 단어일치율 (%)

수능년도	6월 모평	9월 모평
2016	44.60%	46.10%
2017	47.20%	45.50%
2018	48.50%	47.70%
2019	48.90%	48.00%
2020	48.90%	49.20%
2021	46.50%	51.40%

▶ 단어 리스트 (일치 빈도순)

Counter({'food': 14, 'one': 13, 'time': 11, 'experience': 10, 'would': 10, 'also': 10, 'right': 10, 'people': 10, 'sale': 10, 'give': 10, 'new': 9, 'make': 9, 'increase': 9, 'year': 9, 'less': 8, 'many': 8, 'work': 7, 'high': 7, 'school': 7, 'eat': 7, 'produce': 7, 'say': 7, 'human': 7, 'great': 6, 'world': 6, 'among': 6, 'life': 6, 'need': 6...

Advanced Part Ⅱ (지문 유사도 비교)

✓ 6개년도 데이터에 대해 비정형 분석을 수행한 결과, 평균적으로 수능지문의 79.7%가 6월 혹은 9월 모의고사 지문과 유사한 것으로 산출됨

✓ 또한 검출된 유사지문의 79%가 지문의 장르가 일치하는 것으로 분석됨 (안내문, 설명문, 소설, 도표 해석 등)

✓ 이는 글의 전개방식이나 성격에 따라 사용되는 어휘의 차이로 인한 결과라고 추측되며, 따라서 수능 영어에서 요구하는 능력은 글의 종류에 따른 전개방식에 능숙해지는 것임을 추측함

▶ 지문유사도 비교모델

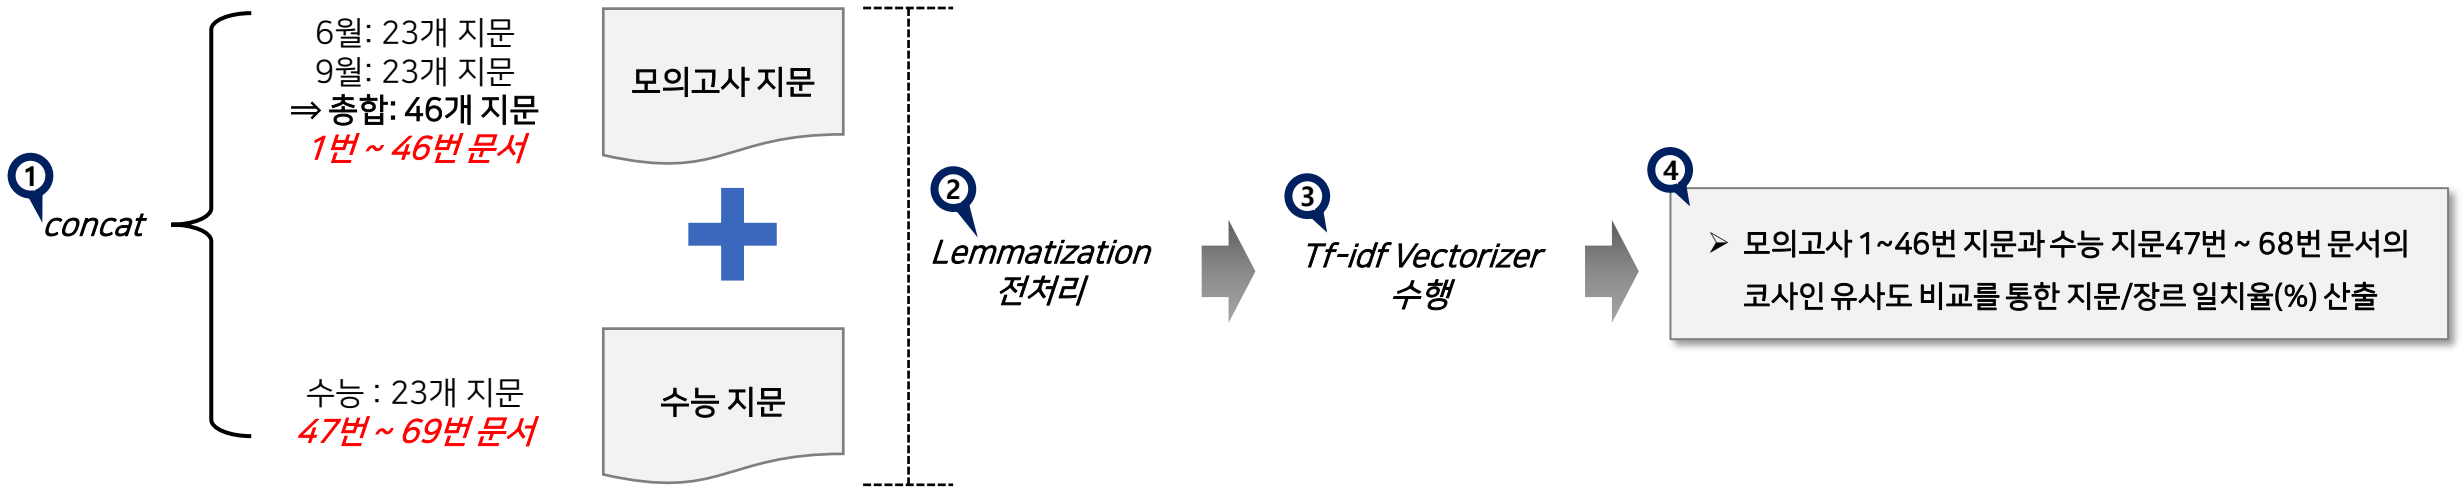


```
import numpy as np
import pandas as pd
import re
from nltk import sent_tokenize
import nltk
from nltk.tokenize import word_tokenize
from nltk.corpus import stopwords
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.metrics.pairwise import cosine_similarity

read6 = pd.read_csv('2016_6월.csv')
read9 = pd.read_csv('2016_9월.csv')
exam = pd.read_csv('2016_수능.csv')
```

<코드4>

```
read6 = read6['contents'].dropna(axis=0)
read9 = read9['contents'].dropna(axis=0)
exam = exam['contents'].dropna(axis=0)
doc = pd.concat([read6, read9, exam], ignore_index=True)
```

⇒ Concat

```
def find_most_similar_news_idf(index, tfidf, corpus):
    idx = (-cosine_similarity(tfidf[index], tfidf)[0]).argsort()[1]
    return {'index':idx,'contents': corpus[idx]}
```

⇒ 코사인 유사도 산출 함수 정의

▶ 지문유사율 / 장르일치율 (%)

구분	2016	2017	2018	2019	2020	2021
모의고사 지문유사율	78.30%	73.90%	78.30%	91.30%	69.60%	87.00%
장르 일치율	95.70%	69.60%	73.90%	78.30%	73.90%	82.60%

Conclusion

- ✓ 데이터를 수집 및 전처리 하는 과정에서 많은 시간이 소요되었으며, 향후 더 많은 학습데이터를 수집하기 위해서는 문제 유형에 따른 PDF를 자동으로 크롤링 해주는 것이 필요
- ✓ 수능 및 평가원 기출문제 외 EBS 지문과 학평 (3,4,7,10월) 시험문제 등이 반영되면 더 좋은 결과를 예측할 수 있을 것이라 판단됨
- ✓ 평가원 기출문제 출제 위원이 실제로도 수능 출제위원으로 문제를 제출하기 때문에 기존에 고안하였던 seq to seq 모델링을 통해 분석한다면 의미있는 결과가 있지 않을까 예상함

- 감사합니다. -